

个人简历

基本信息

姓名：政治面貌：
工作年限：求职岗位：大模型应用开发
电话：邮箱：
学历：毕业院校：
年龄：专业：

技能特长

- 大模型应用核心**：精通RAG全链路开发（文档分块、混合检索、重排序、幻觉抑制）、LangChain/LangGraph框架、多智能体协同系统、MCP协议工具封装、提示词工程与CoT思维链优化
- 大模型微调与部署**：掌握LoRA低秩适配高效微调、Ollama本地模型部署、Embedding模型部署、FastAPI服务化、Docker容器化
- 全栈工程能力**：熟练使用Python（FastAPI、异步编程）、Java（SpringBoot微服务）；精通MySQL、Redis、Milvus向量数据库、Elasticsearch；熟悉RabbitMQ、Nginx、Linux运维
- 生产级保障**：具备完整的大模型应用高可用设计经验，掌握熔断降级、状态持久化、可观测性、并发安全等工业级开发技巧

项目经验

2025-09 ~ 2026-03 XXX企业内部IT工单智能诊断与分配Agent与分配 Agent 项目核心开发

【项目简介】：针对公司内部IT工单分类混乱、响应慢、重复问题多的痛点，基于LangGraph构建三层多Agent协作系统，实现工单自动意图识别、多轮对话诊断与智能分配，完成从“人工全流程处理”到“AI为主、人工为辅”的模式转变。

【技术栈】：LangGraph、LangChain、Qwen大模型、LoRA、Milvus、Elasticsearch、BGE-reranker、Redis、FastAPI、Docker、LangSmith

【核心职责】

- 设计基于StateGraph的三层Agent架构（入口Agent→诊断Agent→分配Agent），实现全局状态共享与节点级状态持久化
- 对Qwen大模型进行LoRA微调，将工单意图分类准确率从85%提升至92%
- 搭建“ES关键词检索+Milvus语义检索”的混合检索体系，引入Cross-Encoder重排序，整体问题命中率提升至94%
- 实现完整的多轮对话能力，支持最多20轮追问，通过滑动窗口与智能截断管理上下文
- 完善生产级可靠性保障：熔断器、宕机恢复、ReAct死循环检测、全链路可观测性

【项目成果】：工单处理效率提升60%，平均处理时长从25分钟降至10分钟，运维人力成本下降35%，幻觉率控制在3%以下，日均处理工单150+

2025-03 ~ 2025-08 乡村政策智能问答助手（基于RAGFlow二次开发） 项目核心开发

【项目简介】：面向乡村政务服务场景，整合微信公众号政策文章、操作手册、办事流程等多源异构文档，构建一站式智能问答系统，解决村民政策咨询难、办事流程不清晰的问题。

【技术栈】：RAGFlow、Milvus、Qwen、Redis、FastAPI、Docker、BeautifulSoup

【核心职责】

- 设计自动化数据采集与清洗流程，定时拉取公众号文章并提取正文，去除噪声信息
- 采用基于标题层级的语义分块策略，保留文档原始结构关系，避免关键信息截断
- 实现高频问题缓存与热更新机制，基于用户反馈动态调整缓存内容
- 对接微信公众号，提供7×24小时在线智能咨询服务

【项目成果】：覆盖2000+村民，常见问题解答耗时从5分钟降至15秒，重复问题咨询量下降70%，缓存命中率达65%，日均LLM调用量减少58%

2024-10 ~ 2025-02

企业级SQL智能取数Agent

项目核心开发

【项目简介】：为解决公司财务、运营部门取数难、依赖技术人员的问题，基于LangChain构建SQL智能取数Agent，支持自然语言转SQL、多表关联查询、数据分析与可视化图表自动生成。

【技术栈】:LangChain、MCP协议、Qwen、MySQL、Redis、FastAPI、ECharts

【核心职责】

- 基于MCP协议封装数据库查询工具，实现表结构自动读取、SQL执行与结果返回
- 设计"表结构理解→SQL生成→语法校验→结果解释"的多阶段执行流程
- 引入CoT思维链优化复杂SQL生成能力，支持多表关联、聚合查询与条件过滤
- 实现结果可视化，自动生成柱状图、折线图、饼图等常用图表

【项目成果】：SQL生成准确率达88%，平均取数时间从2小时缩短至30秒，覆盖公司80%以上的日常取数需求，技术人员取数工作量减少60%

2024-12 ~ 2025-02

工业设备故障诊断知识库系统

项目核心开发

【项目简介】：结合自身工业设备开发经验，构建面向智能家居设备的故障诊断知识库系统，整合设备说明书、故障案例、维修手册等资料，实现故障自动排查与维修建议生成。

【技术栈】:LangChain、Milvus、Elasticsearch、Qwen、FastAPI、Docker

【核心职责】

- 设计完整的RAG系统架构，完成多格式文档解析、分块、向量化与检索全流程
- 优化文档分块策略，采用父子分块+滑动窗口技术，解决长文档语义碎片化问题
- 实现故障现象与解决方案的精准匹配，支持多轮对话式故障排查
- 完成生产级部署，提供标准化的API接口供前端调用

【项目成果】：故障诊断准确率达86%，平均故障排查时间缩短50%，可覆盖90%以上的常见设备故障

工作经历

2023-07 ~ 2026-03

xxx有限公司

大模型应用开发负责人

- 负责公司核心业务系统的后端架构设计与开发，主导传统业务系统向AI驱动的智能升级
- 独立完成4个大模型落地项目的全流程开发，覆盖企业内部运维、政务服务、数据分析、工业制造四大场景
- 搭建公司内部大模型应用开发规范与部署标准，培养2名实习生，推动AI技术在全公司的落地应用

2022-04 ~ 2023-05

xxxx有限公司

后端开发工程师

- 参与智能家居平台开发，负责设备管理与控制模块的后端开发
- 完成WR2数据向边缘网关的迁移，实现数据过滤、清洗及实时同步
- 对接第三方平台设备数据，提供标准化的应用层接口支持

校园经历

2019-09 ~ 2023-06

xxx学院

计算机科学与技术（本科）

自我评价

具备4年扎实的后端开发与工程化经验，已成功完成从传统后端开发到大模型应用开发的技术转型
精通RAG、Agent等当前企业最核心的大模型应用技术，拥有多个从0到1的生产级项目落地经验
学习能力强，对新技术保持高度敏感，注重代码质量与生产环境的稳定性
工作认真负责，具备良好的团队协作与沟通能力，能够独立承担项目并带领团队完成开发任务