

教育背景

工作经历

项目经验

2025-12 ~ 至今

企业级大模型本地化部署与 RAG 问答系统

AI应用开发工程师

项目背景：企业内部 1.0 版智能问答仅支持基础文档检索，存在幻觉率高、复杂问题处理能力弱、无法对接业务系统、答案不可追溯等痛点。主导系统 2.0 全链路升级，基于AI 工程化实践，打造覆盖制度解读、流程审批、故障排查、合规咨询的企业全能智能助手，保障数据隐私与高并发稳定服务。

核心工作：

- 完成Qwen32B 消费级 GPU 本地化部署、LoRA 微调与量化压缩，实现离线稳定运行，推理速度达 20 Token/s（8K 上下文），满足企业数据不出域、高隐私安全要求。
- 深度优化 RAG 全链路，新增重排序模块，采用语义 + 标题混合分块策略，对比多组 Top-K/ 相似度阈值，检索召回率提升 25%，有效降低模型幻觉。
- 融合CoT 思维链推理，构建复杂问题拆解 - 分步回答 - 结果校验体系，支持制度解读、流程审批、故障排查等高阶推理场景；
- 搭建全链路监控 + 问答日志 + 异常告警体系，实现检索失败、生成异常、权限越权快速定位。
- 完成企业内部系统对接，实现数据安全隔离、分级权限管控与操作留痕。

技术架构：

本地化 Qwen32B（LoRA 微调 / INT4 量化）+ LangGraph 多智能体 + Milvus 向量库 + RAGFlow + MCP 工具互联 + RAGAS 自动化评估体系

部署环境：

Windows Server、Docker 容器化、GPU 算力调度、服务化启动

项目成果：

- 覆盖公司5 个部门、200 + 员工，日均处理查询300 + 次，员工信息获取效率提升60%
- 日均减少人工答疑120 + 次，年节省人力成本约15 万元
- 合规问答准确率达98%，上线以来零合规风险、零数据泄露事件
- 工程部署成本较 1.0 版本降低90%，支撑高并发离线稳定服务

2024-08 ~ 2025-11

客户标签智能对话项目

AI应用开发工程师

项目背景：传统银行业务人员查询客户标签依赖固定报表与手写 SQL，使用门槛高、响应慢、数据口径不统一，无法支撑精细化运营与精准营销。基于数据中台 + RAG + 大模型搭建自然语言交互的客户标签智能查询系统，实现标签自助查询、自动统计、智能解读。

核心工作：

- 对接银行核心、信贷、贵金属、银保通、基金、个人特色存款等 7 大业务系统，完成全量 / 增量数据采集、清洗、去重、标准化，构建统一客户标签宽表与标准化标签体系。
- 对比语义 / 段落 / 固定 / 标题4 种分块策略与多组 Top-K 检索参数，确定金融标签场景最优检索方案（语义分块 + Top-K=10）。
- 实现NL2SQL 自然语言转 SQL能力，支持多表关联、条件筛选、聚合计算，自动生成数据结果与可视化解读。
- 搭建日调度数据更新机制，保障标签数据实时性与一致性。

技术架构：

LangChain + Milvus 向量库 + 大模型 + 银行数据中台（STG→DWD→DM→ADM）

数据工具：

DataWorks、DataX、Python；数据库：MySQL、Oracle、Hive

业务数据库:**核心系统数据库**（主要存放对私存款明细数据）、**信用风险管理系统数据库**（存放业务合同及业务流程申请涉及数据）、**贵金属综合交易系统库**（主要存放积存金金额、余额、保证金及其他资产数据）、**银保通系统数据库**（存放理财、资产基金已经信托等产品相关信息及交易数据）、**基金系统数据库**（存放基金相关金额数据）、**个人特色存款管理系统数据库**（主要存放快利加、增利加以及添利加等其他信用产品资产金额）

项目成果：

- 1. 客户标签查询准确率达92%，响应时间缩短73%
- 2. 业务人员零 SQL 基础即可完成数据查询，运营分析效率提升
- 3. 支撑30+场精准营销活动客群筛选，带动相关产品销售额提升12%；
- 4. 替代传统固定报表，降低数据取数分析人力成本

项目背景：传统审计依赖人工查阅海量文档、固定报表与线下查询，风险识别滞后、效率低下，无法满足全行智能化审计、风险实时监控、数据自助查询的管理要求。基于 RAG 与大模型构建审计数据智能问答系统，实现审计指标、风险规则、业务模型自然语言精准检索与智能解析。

- 核心工作**：
- 1.设计审计数据模型，搭建ODS 贴源层 - DW 公共层 - ADS 应用层数据分层架构，统一管理审计历史库、核心系统、信贷系统、汇聚平台多源数据
 - 2.开发审计规则智能解析模块，支持风险规则自然语言检索、逻辑校验、自动解读
 - 3.对比 4 种文档分块策略与混合检索方案，确定语义分块 + Top-K = 10为金融审计场景最优配置。
 - 4.搭建审计问答日志与效果评估体系，通过人工标注 + 自动评估持续优化检索与生成效果。

技术架构：原生 Python + FAISS + ElasticSearch + 大模型；数据分层：ODS→DW→ADS

运维工具：Linux、FileZilla、FinalShell、PostgreSQL、Oracle

- 项目成果**：
- 1. 审计指标查询时间从平均 2 小时缩短至 5 分钟，审计工作效率提升60%
 - 2. 实现100 + 条核心风险规则自动监控，提前发现3 起潜在合规风险
 - 3. 在全行3 个审计部门全面推广，成为日常审计核心工具
 - 4. 降低人工查数、规则核对成本，强化审计合规与风险防控能力

技能特长

- 1. **大模型与部署**：精通 Qwen 等开源大模型本地化部署、LoRA 微调、量化压缩、服务化启动；熟练使用 llamafactory、FastAPI 搭建模型服务；掌握 Docker 容器化、GPU 调度、离线稳定部署。
- 2. **RAG 全栈开发**：精通LangChain、LangGraph、RAGFlow，掌握文档加载 - 分块 - 向量化 - 检索 - 重排序 - 生成全链路；熟练使用 Milvus、FAISS、ElasticSearch 向量数据库；具备 RAGAS 自动化评估、分块 / 召回 / 重排序优化能力
- 3. **数据与工程**：熟练 SQL/Hive SQL，掌握 Oracle/MySQL/PostgreSQL；精通 DataWorks 全流程 ETL、多源数据采集 / 清洗 / 标签构建；熟悉 Hadoop、HDFS、MaxCompute 大数据生态。
- 4. **系统与工具**：熟练 Linux 常用命令、Xshell/FinalShell；掌握 MCP 工具互联、Prompt Engineering、CoT 思维链；具备全链路监控、日志排查、权限管控、系统对接能力。
- 5. **行业能力**：深耕金融行业（银行审计 / 客户标签 / 企业内控），熟悉业务流程、数据口径、合规要求，可独立完成需求分析→方案设计→开发部署→上线运维全流程。

荣誉证书

自我评价

- 1.深耕 AI 大模型应用开发领域，长期专注企业级 RAG、大模型本地化部署、金融行业智能系统落地，技术栈贴合行业主流发展方向
- 2.具备从 0 到 1 搭建智能问答系统全流程经验，擅长 RAG 全链路优化、复杂问题推理、数据安全和合规管控。
- 3.做事严谨负责、注重细节，学习能力强，乐于跟进大模型新技术（多智能体、自动化评估、思维链），能在压力下高效交付项目。
- 4.具备优秀的业务理解与沟通能力，可快速对接业务需求，输出高可用、高稳定、高准确率 AI 应用解决方案。